

# 冗余，而非能力：高熵合金相预测中近重复泄漏与训练数据量的分离

作者：[你的姓名]<sup>1</sup> 单位：<sup>1</sup>[学校名称]，中国北京 通讯：[你的邮箱] 版本：v1，2026 年 9 月 11 日 数据：Zenodo 记录 6403257 (CC-BY-4.0) 代码：[仓库地址]

## 摘要

高熵合金（HEA）相预测的机器学习论文常报 85% – 95% 的准确率，用的多是随机划分。但公开合金数据集里存在大量只差化学计量比的成分，随机划分会让这些近似重复样本同时出现在训练集和测试集。前人已经指出这种冗余会抬高分数，却很少有人把两件事分开：去掉冗余样本和训练数据变少。本文把这两者分离。

用 1,103 条实验报道的合金（350 条固溶体、753 条非固溶体），先确认冗余确实严重：这些合金只落在 449 个不同的元素组合上，74.9% 与其他记录共享同一化学体系，59 组成分完全重复。随后做同尺寸排除扫描：给定半径  $\tau$ （摩尔分数空间的 L1 距离），用「到最近测试样本距离  $\geq \tau$ 」的训练合金训一个模型，再从完整训练池里随机抽同样数量的样本训第二个模型。两者训练样本数完全相同，差别只在于前者不含与测试集邻近的冗余。

梯度提升树在剔除 62% 训练数据后，平衡准确率下降 0.198。其中只有 0.047 来自训练集变小，剩下 0.151（76%）是冗余样本买来的分数。k-NN 表现一致（0.183 中占 0.134，73%），而带正则的逻辑回归几乎不受影响（0.044 中占 0.032，与零不可区分）。效应随  $\tau$  单调增长，且不是由严格的近似重复驱动的：只排除最近的 0.05 距离壳层，梯度提升树只变 0.010。虚高集中在 0.10 – 0.35 区间——同一化学体系、邻近配比。对高容量模型，本数据集上随机划分报出的准确率大约虚高 0.08 – 0.15 平衡准确率，且虚高幅度跟随模型容量，而不是特征选择。

## 1. 为什么要做这件事

典型的 HEA 机器学习论文流程是：从文献收集成分和相标签，算  $\delta$ 、 $\Delta H_{\text{mix}}$ 、 $\Omega$ 、VEC 这些经验判据，训一个分类器，在随机测试集上报准确率。0.85 到 0.95 很常见。

问题在于，实验 HEA 记录不是独立同分布抽样。拿 Al – Co – Cr – Fe – Ni 这样一个体系来说，文献里有几十条合金，彼此只差各元素的比例。随机划分会把其中一部分放进训练、一部分放进测试。容量大的模型于是可以直接回忆一条几乎相同的训练样本，这是记忆，不是泛化。

这类泄漏作为普遍现象早有记录：生命科学领域有专门的数据划分方法 [6]，机器学习科学的可复现性综述也系统讨论过 [7]。我不主张发现了这个现象。针对 HEA，缺的是一个受控的量化：报出的准确率里，多少来自冗余，多少只是更严格的划分被迫缩小训练集造成的，以及这个比例是否取决于模型容量。不把这三者分开，读者无法判断一个 0.86 是「模型会泛化」还是「模型记住了」。

三个问题：

- Q1 一份标准公开 HEA 数据集的冗余有多严重？
- Q2 在训练样本数固定的前提下剔除冗余，会掉多少准确率？取决于模型容量吗？
- Q3 这个效应来自成分空间的哪个部分——完全重复，还是更宽的同体系邻域？

## 2. 数据

来源：

*Materials for Design Open Repository. High Entropy Alloys*

，Zenodo 记录 6403257 [1]，许可 CC-BY-4.0。原始工作簿只下载一次，全程未修改。

目标标签是 S\_Phase，记录相组成：SS（固溶体）、SS+IM、IM（金属间化合物）、AM（非晶）。14 条无标签记录被剔除，剩 1,103 条。主任务二值化：SS 对非 SS。正类 350 条，基准率 31.7%，所以「全预测非 SS」这种平凡策略的原始准确率就有 0.683。下文一律用平衡准确率，平凡策略在该指标上是 0.500。

特征为 78 个元素摩尔分数加 9 个设计判据（ $\delta$ 、 $\Delta H_{\text{mix}}$ 、 $S_{\text{id}}$ 、 $\Omega$ 、 $\text{VEC}$ 、 $\sigma_{\text{VEC}}$ 、 $\Delta\chi$ 、 $\chi$ 、 $T_{\text{m}}$ ）。 $\Omega$  按 Yang & Zhang 定义重算， $\Omega = T_{\text{m}} \cdot \Delta S_{\text{mix}} / |\Delta H_{\text{mix}}|$  [3]，不直接取表格值。

2.1 数据集的冗余结构




图 1. 冗余结构。左：元素组合规模的分布。右：共享化学体系的合金占比。

| 指标          | 数值         |
|-------------|------------|
| 有标签合金       | 1,103      |
| 固溶体（正类）     | 350（31.7%） |
| 不同元素组合      | 449        |
| 处于共享化学体系的合金 | 74.9%      |
| 最大单一体系      | 45 条       |
| 成分完全重复      | 59 组       |
| 至少出现一次的元素   | 57 种       |

平均每个化学体系 2.5 条，但分布长尾：少数热门体系（Al – Co – Cr – Fe – Ni 及其子集、难熔的 Mo – Nb – Ta – V – W、Ti – Zr – Hf 系）贡献了数据集里很大一块。对这种表做随机划分，不等于对成分空间做随机划分。

### 3. 方法

---

#### 3.1 模型

覆盖容量跨度较大的三个族：

- 逻辑回归——中位数填补、标准化、L2 惩罚 ( $C = 1$ )、类别平衡权重。低容量，强正则。
- 直方图梯度提升树——150 轮，学习率 0.08，15 个叶子， $L2 = 1.0$ 。高容量。
- k-NN—— $k = 5$ ，距离加权，标准化特征上用 cityblock 距离。纯基于实例的记忆模型；如果泄漏本质是记忆，它应该最明显。

#### 3.2 评估协议

1. 随机分层交叉验证（5 折，3 次重复）。
2. 化学体系分组交叉验证——StratifiedGroupKFold，以元素组合为组，任何体系都不跨划分。
3. 受控配对实验——固定 20% 分层测试集。TrainA\_matched 从完整训练池随机抽样；TrainB\_disjoint 只保留与测试集任何合金都不共享元素组合的合金，并抽样到相同规模。同一测试集、同一训练规模，10 次划分，Wilcoxon 符号秩检验。（不相交池较小，匹配前只保留完整池的 50.6%。）
4. 近重复排除扫描（本文新增，核心）。见下节。
5. 留一元素法——取 18 种高频元素；训练时不含元素 X，只在含 X 的合金上测试。

指标为平衡准确率、MCC、ROC-AUC。置信区间用 2,000 次自助重采样。所有随机种子写在脚本里。

#### 3.3 排除扫描

协议 1–3 能说明冗余有影响，但说不清下降中有多少是冗余造成的。协议 4 专门解决这个。

固定测试集  $T$ 。给定半径  $\tau$ ，对训练池里每条合金，算它到  $T$  中最近样本的 L1 距离（摩尔分数空间）。然后构造两个规模完全相同（均为  $n$ ）的训练集：

- $\text{excluded}(\tau)$ ——距离  $\geq \tau$  的合金。与测试集邻近的冗余被物理剔除。
- $\text{matched}(\tau)$ ——从完整训练池里均匀随机抽  $n$  条。冗余仍在其中，但训练数据量完全相同。

用同一个模型分别训练，在同一个  $T$  上评分。定义

$$\Delta(\tau) = \text{平衡准确率}(\text{matched}(\tau)) - \text{平衡准确率}(\text{excluded}(\tau))。$$

两者训练集规模相同，差异无法归因于数据量。它就是邻近测试集的冗余所供给的那部分准确率。扫描  $\tau$  可以刻画这份贡献在成分空间里的分布：小  $\tau$  只隔离完全重复和近乎完全重复，大  $\tau$  覆盖整个同体系邻域。

共 7 个半径： $\tau \in \{0, 0.02, 0.05, 0.08, 0.12, 0.20, 0.35\}$ ，3 次划分。 $\tau = 0$  时两个集合按构造完全一致，用作正确性检查。

---

## 4. 结果

### 4.1 经典判据到底值多少




图 2. 经典判据窗口内的类别重叠。




图 3. 各相类别下的判据分布。

| 判据                                         | 平衡准确率 | 95% CI         | 灵敏度   | 特异度   | MCC    |
|--------------------------------------------|-------|----------------|-------|-------|--------|
| 全预测「非 SS」                                  | 0.500 | [0.500, 0.500] | 0.000 | 1.000 | 0.000  |
| $\delta \leq 6.6\%$                        | 0.716 | [0.690, 0.740] | 0.860 | 0.571 | 0.405  |
| $-15 \leq \Delta H_{mix} \leq 5$ kJ/mol    | 0.689 | [0.663, 0.714] | 0.874 | 0.505 | 0.363  |
| $\Omega \geq 1.1$                          | 0.714 | [0.692, 0.736] | 0.943 | 0.486 | 0.419  |
| $3 \leq VEC \leq 8$                        | 0.479 | [0.453, 0.504] | 0.774 | 0.183 | -0.050 |
| $\Delta\chi \leq 0.3$                      | 0.533 | [0.518, 0.548] | 0.966 | 0.101 | 0.114  |
| $\delta$ 与 $\Delta H_{mix}$ 合用             | 0.731 | [0.704, 0.757] | 0.797 | 0.665 | 0.431  |
| $\delta + \Delta H_{mix} + \Omega$ (经典三判据) | 0.753 | [0.725, 0.779] | 0.786 | 0.720 | 0.474  |
| $\delta + \Delta H_{mix} + \Omega + VEC$   | 0.678 | [0.649, 0.708] | 0.569 | 0.788 | 0.354  |




图 4. 经典判据对比单判据最优阈值。

$\delta$ 、 $\Delta H_{mix}$ 、 $\Omega$  三者合取达到 0.753，是经典规则里最好的。加上 VEC 反而变差（0.678），因为 VEC 窗口对「是不是固溶体」这个问题区分力很差——它是为另一个问题设计的，即形成哪种晶格。

这个区分很重要。只看相为纯 FCC 或纯 BCC 的 220 条合金，套用  $VEC \geq 8 \rightarrow \text{FCC}$ 、 $VEC \leq 6.87 \rightarrow \text{BCC}$  规则，得到 163 个可判定案例（覆盖率 74.1%），163 条全对。所以「能否形成固溶体」和「形成哪种晶格」是两个难度差很远的问题，VEC 把第二个答得很好，对第一个几乎无用。

阈值调优后的单判据天花板很低：

| 判据               | 方向      | 交叉验证平衡准确率         |
|------------------|---------|-------------------|
| $\Omega$         | 越大越像 SS | $0.742 \pm 0.029$ |
| $S_{id}$         | 越大越像 SS | $0.730 \pm 0.020$ |
| $\delta$         | 越小越像 SS | $0.728 \pm 0.021$ |
| $\Delta H_{mix}$ | 越大越像 SS | $0.684 \pm 0.025$ |
| $\Delta \chi$    | 越小越像 SS | $0.677 \pm 0.023$ |
| $T_m$            | 越大越像 SS | $0.628 \pm 0.024$ |
| $\sigma_{VEC}$   | 越小越像 SS | $0.609 \pm 0.022$ |
| VEC              | 越小越像 SS | $0.513 \pm 0.024$ |

即使阈值由交叉验证最优选取，也没有任何单判据超过 0.742。经典三判据合取与之持平。任何声称在这个任务上做到 0.90+ 的机器学习模型，都在做判据本身做不到的事——而这种情况恰恰最值得追问它在做什么。

## 4.2 随机划分对比分组划分




图 5. 同一模型、同一数据、两种划分协议。

| 特征      | 模型     | 随机分层  | 体系分组  | 差值     |
|---------|--------|-------|-------|--------|
| 仅成分     | logreg | 0.787 | 0.730 | +0.057 |
| 仅成分     | hgb    | 0.837 | 0.760 | +0.077 |
| 仅 9 个判据 | logreg | 0.798 | 0.796 | +0.002 |
| 仅 9 个判据 | hgb    | 0.850 | 0.763 | +0.087 |
| 成分 + 判据 | logreg | 0.807 | 0.769 | +0.038 |
| 成分 + 判据 | hgb    | 0.859 | 0.776 | +0.083 |

两点值得注意。梯度提升树无论拿到什么特征都掉 0.077 – 0.087，包括只拿到 9 个聚合判据、完全看不到成分的时候。而逻辑回归在只看判据时几乎不动 (+0.002)，在原始成分上掉 0.057。分组只在这个低容量模型拿到「能直接识别化学体系」的输入时才伤到它。

## 4.3 受控配对比较

固定测试集、匹配训练规模，消掉最后一个混杂因素：

| 特征      | 模型     | TrainA_matched | TrainB_disjoint | $\Delta$ | 95% CI           | p       |
|---------|--------|----------------|-----------------|----------|------------------|---------|
| 仅成分     | hgb    | 0.787          | 0.638           | +0.150   | [+0.106, +0.230] | 2.0e-03 |
| 成分 + 判据 | hgb    | 0.829          | 0.696           | +0.133   | [+0.063, +0.196] | 2.0e-03 |
| 仅 9 个判据 | hgb    | 0.806          | 0.690           | +0.116   | [+0.067, +0.155] | 2.0e-03 |
| 仅成分     | logreg | 0.774          | 0.721           | +0.053   | [+0.025, +0.090] | 2.0e-03 |
| 成分 + 判据 | logreg | 0.807          | 0.784           | +0.023   | [-0.008, +0.055] | 2.7e-02 |
| 仅 9 个判据 | logreg | 0.803          | 0.783           | +0.021   | [-0.010, +0.049] | 9.8e-03 |

对梯度提升树，在训练规模相同、测试集相同的情况下，仅「化学体系不相交」这一项就值 +0.133 平衡准确率。对逻辑回归，同样的操弄只值 +0.023，置信区间包含零。

注意只用 9 个判据的梯度提升模型仍然涨 +0.116。这 9 个判据是成分的确定性函数，所以这不是「效应跟特征有关」的证据。它说明效应跟着样本走，不跟着表示走。

## 4.4 把冗余与训练数据量分开




图 8. (a) 固定测试集上的平衡准确率随排除半径变化。虚线：同尺寸对照；实线：剔除近重复。(b) 两者之差。

配对实验显示冗余值 0.13，但批评者仍可说：不相交池是另一个更难子总体。扫描把这个反驳也堵上——它让训练规模严格保持不变。

| $\tau$ | 训练规模 | 同尺寸对照 | 剔除近重复 | $\Delta$ |
|--------|------|-------|-------|----------|
| 0.00   | 882  | 0.883 | 0.883 | 0.000    |
| 0.02   | 841  | 0.873 | 0.852 | +0.021   |
| 0.05   | 787  | 0.855 | 0.845 | +0.010   |
| 0.08   | 720  | 0.853 | 0.829 | +0.024   |
| 0.12   | 643  | 0.863 | 0.782 | +0.081   |
| 0.20   | 504  | 0.827 | 0.735 | +0.092   |
| 0.35   | 333  | 0.836 | 0.685 | +0.151   |

(梯度提升树，3 次划分的均值。 $\tau = 0$  一行是正确性检查——两个集合按构造完全相同。)




图 9. 总下降如何在「训练集变小」与「剔除冗余」之间分配。

$\tau = 0.35$  时，62% 的训练数据已被剔除。随机抽到同样 333 条的同尺寸对照仍有 0.836，只比 0.883 的基线低一点。剔除后的集合只有 0.685。于是：

| 模型           | 总下降   | 来自训练集变小 | 来自冗余  | 冗余占比      |
|--------------|-------|---------|-------|-----------|
| 梯度提升树        | 0.198 | 0.047   | 0.151 | 76%       |
| k-NN (k = 5) | 0.183 | 0.049   | 0.134 | 73%       |
| 逻辑回归         | 0.044 | 0.012   | 0.032 | 74% (不显著) |

对两个高容量模型，更严格的评估协议带来的表现代价里，约四分之三是冗余，不是数据量。逻辑回归那一行则让整个叙述自洽：它的 0.032 小于划分间波动，说明线性模型基本不在乎近重复在不在。

$\tau$  依赖性是最有意思的部分，而且和我一开始的预期相反。

- 严格的近重复贡献极小。把训练集里所有与测试样本 L1 距离在 0.05 以内的合金全部删掉——训练集缩水 11%，而 25.5% 的测试样本本来有这样一个邻居（见 4.5 节）——梯度提升树的准确率只动 0.010。删「重复项」不是解法所在。
- 虚高集中在中间带。 $\Delta$  从  $\tau = 0.05$  时的 0.010 升到  $\tau = 0.12$  时的 0.081， $\tau = 0.20$  时 0.092。起作用的冗余不是成分完全相同，而是同一化学体系、不同配比——模型仍能对它们记住一个局部答案。
- 单调且受容量门控。梯度提升树和 k-NN 的  $\Delta$  稳定上升；逻辑回归在零附近震荡（ $\tau \geq 0.02$  的均值为 0.005，最大 0.032，与划分间波动同量级）。

#### 4.5 机制：最近邻成分距离




图 6. 每个测试样本到其最近训练邻居的距离分布。

| 量            | TrainA（随机） | TrainB（不相交） |
|--------------|------------|-------------|
| 最近邻距离中位数     | 0.120      | 0.333       |
| 距离 < 0.05 占比 | 25.5%      | 2.8%        |
| 距离 < 0.10 占比 | 43.5%      | 6.5%        |

随机划分下，四分之一测试集有几乎相同的训练对应物，近一半落在 0.10 以内。不相交划分下这些数字崩塌。这就是上面所有结果的机制，也解释了为什么扫描的中间带（0.10 – 0.20）才是准确率的藏身处：测试集的邻居大部分就住在那里。

## 4.6 留一元素外推




图 7. 完全留出单一元素时的平衡准确率。

每次留出一种元素——训练时不用它，只在含它的合金上测试——平均平衡准确率 0.665（标准差 0.133，范围 0.420 – 0.931），平均 ROC-AUC 0.776。对比随机划分的 0.859，差距接近 0.2。失败模式在化学上说得通：Al（0.600）和 Si（0.567）是强金属间化合物形成元素；Mg（0.500）和 B（0.500）数据太少，学不到东西。外推最好的是 Zr（0.931）和 Hf（0.904），它们与数据里已有的元素化学性质相近。

## 5. 结论与建议

对这份数据集，以及任何具有「一个体系、多种配比」结构的 HEA 数据集：

1. 随机划分的数字不是泛化能力估计。高容量模型在本数据上虚高 0.08 – 0.15 平衡准确率，比多数模型架构之间的差距还大。
2. 至少报一个化学体系不相交的划分。只需多写一行代码（把元素组合作为 group 传给 `GroupKFold`），但它对论文结论的影响超过大多数超参搜索。
3. 报平衡准确率和 MCC。正类率 31.7%，全预测多数类的原始准确率就是 0.683，原始准确率会美化这个任务上的所有模型。
4. 不必去重完全相同的成分。这是最直觉的做法，但几乎什么都换不回来（0.010）。真正起作用的是结构性冗余，分散在同体系邻居里。 $\tau \approx 0.10 - 0.20$  的距离排除，或者元素组合划分，才真正咬得动。
5. 把两个问题分开。「能否形成固溶体」很难（判据上限约 0.75），「FCC 还是 BCC」很容易（可判定子集上 100%）。混在一起报，两个事实都被掩盖。
6. 用留一元素外推做压力测试。成本低，且能暴露模型真正学会了哪些元素、记住了哪些。

测量协议本身可迁移。任何记录会聚成家族的数据集——材料、生物活性系列、同一站点的临床队列——都能跑同一套扫描：固定测试集，变动排除半径，报出在训练规模匹配时表观数字还剩多少。

## 6. 局限

- 单一数据源。幅度是这份表特有的。方向与容量依赖应当可迁移，但 0.151 这个具体数字不能当作通用常数引用。

- 标签噪声。标签来自文献聚合，制备工艺和热处理历史没有记录。SS+IM 本身是中间类别，很可能是不可约误差的最大来源。
- 分组是近似的。「同一元素组合」是「同一化学家族」的粗糙代理，排除扫描用的是原始成分距离，不考虑化学性质。更严格的分组会给出更大的效应，所以本文数字是下界。
- 只有三个模型族，没有容量扫描。为保持协议可比，刻意没有调超参。沿连续轴变动树深或正则强度的容量扫描能显示「不在乎」到「在利用」的转变发生在哪里。
- 扫描只有 3 次划分。 $\tau = 0.35$  的配对  $\Delta$  远在划分间波动之外，但中间半径 ( $\tau = 0.05 - 0.08$ ) 各自无法分辨。结论是单调趋势，不是单个小数值。
- 没有外部验证。全部是对已发表数据的再分析，未与任何新实验对照。

## 7. 可复现性

```
research/  
├── data/      原始工作簿（只读）+ 清洗后的 parquet/csv  
├── code/      hea_common.py, 00_profile.py, 01_build_dataset.py,  
              02_criteria_audit.py, 03_leakage_experiment.py,  
              04_figures.py, 05_report.py, 06_report_en.py,  
              07_exclusion_sweep.py, 08_paper_figures.py  
├── out/      结果 JSON/CSV, 上文所有数字  
├── figures/   9 张 300 dpi 图  
└── report/   完整 HTML 与 Markdown 报告（中英文）
```

```
cd research/code  
python 00_profile.py && python 01_build_dataset.py && python 02_criteria_audit.py  
python 03_leakage_experiment.py stage1  
python 03_leakage_experiment.py stage2  
python 03_leakage_experiment.py merge  
python 07_exclusion_sweep.py run  
python 07_exclusion_sweep.py merge  
python 04_figures.py && python 08_paper_figures.py
```

Python 3.13，依赖 numpy、pandas、scipy、scikit-learn、matplotlib、openpyxl、pyarrow。所有随机种子写在脚本里。本文每个数字都在构建时从 `out/` 下的结果文件读取，无一手抄。

## 声明

AI 工具使用。本研究在 AI 系统的大量协助下完成：AI 运行了分析流程、生成了图表、起草了文本。AI 没有生成任何数据，全部数据为第三方已发表测量结果。作者确定了研究问题、审查了分析过程，并对内容（含任何错误）负责。本声明依照现行出版方关于 AI 辅助研究的政策提供，读者应据此评估结果。

数据可用性。Zenodo 记录 6403257，DOI 10.5281/zenodo.6403257，CC-BY-4.0。数据集未被修改。

代码可用性。[仓库地址——投稿前填写。]

利益冲突。无。

资助。无。

## 参考文献

---

1. Precker, C. E., Gregores Coto, A. & Muñíos Landín, S. *Materials for Design Open Repository. High Entropy Alloys*. Zenodo (2021). DOI 10.5281/zenodo.6403257. CC-BY-4.0. (数据来源)
  2. Zhang, Y., Zhou, Y. J., Lin, J. P., Chen, G. L. & Liaw, P. K. Solid-solution phase formation rules for multi-component alloys. *Advanced Engineering Materials* **10**, 534 – 538 (2008). ( $\delta$  判据)
  3. Yang, X. & Zhang, Y. Prediction of high-entropy stabilized solid-solution in multi-component alloys. *Materials Chemistry and Physics* **132**, 233 – 238 (2012). ( $\Omega$  判据)
  4. Guo, S. & Liu, C. T. Phase stability in high entropy alloys. *Progress in Natural Science: Materials International* **21**, 433 – 446 (2011). (VEC 判据)
  5. Guo, S., Ng, C., Lu, J. & Liu, C. T. Effect of valence electron concentration on stability of fcc or bcc phase in high entropy alloys. *Journal of Applied Physics* **109**, 103505 (2011). ( $\text{VEC} \geq 8 \rightarrow \text{FCC}$ )
  6. Joachimiak, M. P., Nielsen, J. S. & Winther, O. Data splitting to avoid information leakage with DataSAIL. *Nature Communications* **16** (2025).
  7. Kapoor, S. & Narayanan, A. Leakage and the reproducibility crisis in machine-learning-based science. *Patterns* **4**, 100804 (2023).
- 

数据集属于其原始作者；本文不构成对任何具体已发表工作的批评。主张是有限的：在这份数据上、按这套协议，报出的准确率里有这么多来自冗余。